



project work

HS16 Studiengang Informatik

Spaghetti Bolognese mit Parmesan

Autoren

Raphael Emberger, Kal-El,
Musashi Miyamoto

Datum

19. November 2017

Bitte füllen Sie das Titelblatt aus und berücksichtigen Sie Folgendes:

-> Bitte auf keinen Fall Schriftart und Schriftgrösse ändern. Text soll lediglich überschrieben werden!

-> Bitte pro Tabellenzeile max. 4 Textzeilen!

- Titel: Fügen Sie Ihren Studiengang direkt nach dem Wort „Project Work“ ein (max. 2 Zeilen).
- Titel der Arbeit: Überschreiben Sie den Lauftext mit dem Titel Ihrer Arbeit (max. 4 Zeilen).
- Autoren: Tragen Sie Ihre Vor- und Nachnamen ein (alphabetisch nach Name).
- Betreuer: Tragen Sie Ihren Betreuer / Ihre Betreuer ein (alphabetisch nach Name).
- Ohne Nebenbetreuung, Industriepartner oder externe Betreuung, ganze Tabellenzeile löschen.
- Am Schluss löschen Sie den ganzen Beschrieb (grau) und speichern das Dokument als pdf. ab.

Zusammenfassung

- Zusammenfassung

Vorwort

- Stellt den persönlichen Bezug zur Arbeit dar und spricht Dank aus.

DECLARATION OF ORIGINALITY

Project Work at the School of Engineering

By submitting this project work, the undersigned student confirms that this thesis is his/her own work and was written without the help of a third party. (Group works: the performance of the other group members are not considered as third party).

The student declares that all sources in the text (including Internet pages) and appendices have been correctly disclosed. This means that there has been no plagiarism, i.e. no sections of the Bachelor thesis have been partially or wholly taken from other texts and represented as the student's own work or included without being correctly referenced.

Any misconduct will be dealt with according to paragraphs 39 and 40 of the General Academic Regulations for Bachelor's and Master's Degree courses at the Zurich University of Applied Sciences (Rahmenprüfungsordnung ZHAW (RPO)) and subject to the provisions for disciplinary action stipulated in the University regulations.

City, Date:

Signature:

.....

.....

.....

.....

The original signed and dated document (no copies) must be included after the title sheet in the ZHAW version of all Bachelor thesis submitted.

Inhaltsverzeichnis

1. Introduction	9
1.1. Initial Position	10
1.2. Task	10
2. Theoretical Principles	12
2.1. Definitions	12
2.2. Recurrent Neural Networks	12
2.3. Seq2Seq	12
2.4. Attention	12
2.5. Performance Evaluation	12
3. Experiments	13
4. Results	14
5. Discussion and Prospects	15
6. Index	16
6.1. Literaturverzeichnis	16
6.2. Glossary	17
6.3. Abbildungsverzeichnis	18
6.4. Tabellenverzeichnis	19
6.5. Symbol Glossary	20
6.6. Acronym Glossary	21
A. Appendix	23
A.1. Projektmanagement	23
A.2. Final Words	23

Abstract

- Summary

This is just some normal text that goes here

Preface

- Stellt den persönlichen Bezug zur Arbeit dar und spricht Dank aus.

thank-yous go here

1. Introduction

The rapid pace at which the human species has overcome barriers of communication in the past 100 years is astounding. From the introduction of traditional carrier mail [1] to the invention of the internet [citation needed] one of our only common subjectively goals is the improvement of communication. [citation needed]

However, it is only through the internet that we have the possibility to engage people from all over the globe at the touch of a finger. This ability brings into focus one of the last remaining barriers of communication we have to overcome. In 2009 we spoke 6909 unique languages [?]. Therefore, finding a way to efficiently translate between any of these languages is key.

The rapid advancements in machine learning has put computer scientists in a position to develop machine translators. The currently developed translators can be classified into one of five major groups.[Citation Needed]

1. Rule-Based
2. Statistical
3. Example-Based
4. Hybrid Machine Translation
5. Neural Machine Translation

There are three major challenges in automating translation lies in the nature of all spoken languages.

1. Ambiguity - Words may contain multiple meanings and depending on the context, only a subset apply
2. Non-Standard Terminology - This refers to the use of language constructs which do not adhere to the official language documentation. A popular example of this is are the abbreviations and emojis used in tweets.
3. Named Entities - To a machine, a name appears like any other word. It's a set of characters. However, they are typically not translatable and thus the machine needs to be in a position to accurately identify named entities.

They are ambiguous, contain non-standard constructs and include named entities.

- humans are the most communicative mammal on this planet (source needed)
- our species has relentlessly pursued the improvement of communication methods. First carrier mail, then the telegram followed by the radio, telephone, tv and most recently, the internet.
- The last innovation enabled us truly to connect with [insert percentage of people on the planet who have access to internet] of earth's population.
- One major challenge remains. Language barriers.
- Rise of machine learning has begun to help us overcome this barrier. [Examples of Microsoft (Skype), Google (translate/nmt) and Deepl]
- machines becoming better at processing human language (accuracy)

- translations are still not always 100% correct due to factors such as
 - double meaning
 - context
 - sentiment (sarcasm vs. criticism)
- this project is aimed at building our own neural machine translation agent, rebuilding current nmts and verifying their published performance as well as measure our nmt against the published performance and our measured performance
- attention to correct words
- database structures
- multiple ways to ask for identical information
- multiple solutions proposed
- KBQA: Learning Question Answering over QA Corpora and Knowledge Bases
- Eric, Manning - 2017 - Key-Value Retrieval Networks for Task-Oriented Dialogue - With Highlights
- Asking your Assistant (Google, Siri or S-Voice) weather you have an appointment tomorrow and ask follow-up questions about this appointment is currently not possible (due to above challenges but could be if these papers prove implementable)

1.1. Initial Position

- No Response from KBQA for Code
- Refusal to share code from Manning
- Ultimate new goal: Implement Manning's solution without his code
- Nennt bestehende Arbeiten/Literatur zum Thema -> Literaturrecherche
- Stand der Technik: Bisherige Lösungen des Problems und deren Grenzen
- (Nennt kurz den Industriepartner und/oder weitere Kooperationspartner und dessen/deren Interesse am Thema Fragestellung)

1.2. Task

- Small Steps
 - implement seq2seq network for translation
 - * implement char-based
 - * implement word-based
 - * try multiple different implementations (reversed-input, multiple LSTMs) and compare against each other
 - * get decent results on both and move on
 - implement seq2seq with attention

- * attempt various attention mechanism
- One Large Step
 - map best working models and tools to KBQA and get better results than Stanford
 - Rub better results in Eric's face.
 - Profit.
- Formuliert das Ziel der Arbeit
- Verweist auf die offizielle Aufgabenstellung des/der Dozierenden im Anhang
- (Pflichtenheft, Spezifikation)
- (Spezifiziert die Anforderungen an das Resultat der Arbeit)
- (Übersicht über die Arbeit: stellt die folgenden Teile der Arbeit kurz vor)
- (Angaben zum Zielpublikum: nennt das für die Arbeit vorausgesetzte Wissen)
- (Terminologie: Definiert die in der Arbeit verwendeten Begriffe)

2. Theoretical Principles

Test this one here too, please

```
1 int getRandomNumber()  
2 {  
3     return 4; // chosen by fair dice roll.  
4     // guaranteed to be random.  
5 }
```

2.1. Definitions

- Hypothesis
- Reference

2.2. Recurrent Neural Networks

- Standard Neural Networks
- Recurrent Neural Networks
 - Problems
 - Solutions

2.3. Seq2Seq

- encoder
- decoder

2.4. Attention

- Mechanisms

2.5. Performance Evaluation

- Translation
 - Bleu
 - others
- KB-Retrieval
 - Bleu
 - sent2vec

3. Experiments

- Folgende waren schlechter als in deren Literatur beschrieben
 - Keras Tutorial Char-Based
 - MagicMagic Keras Char = Keras Word
 - Our attempt at Word Based
- Hidden State(?)
- Used Keras Tutorial from TF-Talk
- Google NMT
- Find out why ours didn't perform as well as the above two

- (Beschreibt die Grundüberlegungen der realisierten Lösung (Konstruktion/Entwurf) und die Realisierung als Simulation, als Prototyp oder als Software-Komponente)
- (Definiert Messgrößen, beschreibt Mess- oder Versuchsaufbau, beschreibt und dokumentiert Durchführung der Messungen/Versuche)
- (Experimente)
- (Lösungsweg)
- (Modell)
- (Tests und Validierung)
- (Theoretische Herleitung der Lösung)

4. Results

- (Zusammenfassung der Resultate)

5. Discussion and Prospects

Wie in XXX nachzulesen, gibt es sogenannte Gleichungen. Ω

- Bespricht die erzielten Ergebnisse bezüglich ihrer Erwartbarkeit, Aussagekraft und Relevanz
- Interpretation und Validierung der Resultate
- Rückblick auf Aufgabenstellung, erreicht bzw. nicht erreicht
- Legt dar, wie an die Resultate (konkret vom Industriepartner oder weiteren Forschungsarbeiten; allgemein) angeschlossen werden kann; legt dar, welche Chancen die Resultate bieten

6. Index

6.1. Literaturverzeichnis

Union, U. P. (2016), 'History'.

URL: <http://www.upu.int/en/the-upu/history/about-history.html> 9

6.2. Glossary

élite select group or class 17

élitism advocacy of dominance by an élite 15

6.3. Abbildungsverzeichnis

6.4. Tabellenverzeichnis

6.5. Symbol Glossary

Ω unit of electrical resistance 15

6.6. Acronym Glossary

HRZ Hochschulrechenzentrum 15

[title=Index]

A. Appendix

A.1. Projektmanagement

- Offizielle Aufgabenstellung, Projektauftrag
- (Zeitplan)
- (Besprechungsprotokolle oder Journals)

A.2. Final Words

- CD mit dem vollständigen Bericht als pdf-File inklusive Film- und Fotomaterial
- (Schaltpläne und Ablaufschemata)
- (Spezifikationen u. Datenblätter der verwendeten Messgeräte und/oder Komponenten)
- (Berechnungen, Messwerte, Simulationsresultate)
- (Stoffdaten)
- (Fehlerrechnungen mit Messunsicherheiten)
- (Grafische Darstellungen, Fotos)
- (Datenträger mit weiteren Daten(z. B. Software-Komponenten) inkl. Verzeichnis der auf diesem Datenträger abgelegten Dateien)
- (Softwarecode)